

STA401

**Statistique et Calcul
des Probabilités**

Responsable : Carole Durand-Desprez



**CHAPITRE 2 : Lois continues
"autour de la loi Normale"**

1. Lois continues - Généralités

X une variable aléatoire, $\Omega = I$ (intervalle de toutes les réalisations) \longrightarrow continue

Les probabilités sont définies sur des intervalles par la fonction de répartition

\longleftrightarrow aire sous la courbe de densité f .



$$P(\Omega) = 1$$

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

$$f(x) = F'(x)$$

$$P(a \leq X \leq b) = \int_a^b f(t) dt$$

$$P(a \leq X \leq b) = P(X \leq b) - P(X \leq a)$$

$$P(X \geq a) = 1 - P(X \leq a)$$



$$E[X] = \mu = \int x f(x) dx$$

$$V[X] = \sigma^2 = E[X - E[X]]^2 = E[X^2] - E[X]^2$$

$$V[X] = \int (x - \mu)^2 f(x) dx = \int x^2 f(x) dx - \mu^2$$

Propriétés : (identiques au cas discret)

$$E[aX + bY] = aE[X] + bE[Y]$$

$$V[X] = E[X - E[X]]^2 = E[X^2] - (E[X])^2$$

$$V[aX + b] = a^2 V[X]$$

Inégalité de Markov : X v.a. positive, pour tout $a > 0$:

$$P(X \geq a) \leq \frac{E(X)}{a}$$

$$\text{Dém : } E(X) = \int_0^{\infty} x f(x) dx = \int_0^a x f(x) dx + \int_a^{\infty} x f(x) dx \geq \int_a^{\infty} x f(x) dx$$

$$E(X) \geq a \int_a^{\infty} f(x) dx \geq aP(X \geq a)$$

Inégalité de Bienaymé Tchebychev

Soit X v.a. positive, pour tout $a > 0$:

$$P(|X - E(X)| \geq a) \leq \frac{V(X)}{a^2}$$



La loi Uniforme continue sur [a ; b] (vue au lycée)

Densité : $f(x) = \frac{1}{b-a} \text{ si } a \leq x \leq b ; f(x) = 0 \text{ sinon}$

Espérance et variance : $E[X] = \frac{a+b}{2} \quad V[X] = \frac{(b-a)^2}{12}$



La loi Exponentielle de paramètre λ (avec $\lambda > 0$) :

Densité : $f(x) = \lambda e^{-\lambda x} \text{ si } x \geq 0 ; f(x) = 0 \text{ sinon}$

Espérance : $E[X] = \frac{1}{\lambda}$

Variance : $V[X] = \frac{1}{\lambda^2} \quad (2 \text{ IPP})$

Démo : $E[X] = \int_0^{\infty} \lambda x e^{-\lambda x} dx = \lim_{t \rightarrow \infty} [-x e^{-\lambda x}]_0^t + \lim_{t \rightarrow \infty} \int_0^t e^{-\lambda x} dx \quad (IPP)$

$$E[X] = \lim_{t \rightarrow \infty} [-x e^{-\lambda x}]_0^t - \frac{1}{\lambda} \lim_{t \rightarrow \infty} [e^{-\lambda x}]_0^t = \frac{1}{\lambda}$$

Propriété : $P(X > s+t | X > t) = P(X > s)$ (loi sans mémoire, sans vieillissement)

Démo : $P(X > s+t | X > t) = \frac{P(X > s+t)}{P(X > t)}$; de plus $P(X > s+t) = e^{-\lambda(s+t)}$
et $P(X > t) = e^{-\lambda t}$. On en déduit l'égalité voulue.

2. La loi Normale (Gauss) :




La loi Normale $N(\mu; \sigma^2)$:

Densité :
$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Espérance : $E[X] = \mu$

Variance : $V[X] = \sigma^2$




La loi Normale centrée réduite $N(0;1)$:

Densité :
$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

Espérance : $E[X] = 0$

Variance : $V[X] = 1$




⇒ Lecture des tables statistiques (pas de calcul d'intégrales !):

Loi de Gauss (Normale), Student, Khi-deux, Fisher ...

Notation importante :

x_p quantile d'ordre p : $F(x_p) = P(X \leq x_p) = p$



Convention – Notation :

Pour la loi Normale centrée-réduite, on notera u_p le quantile d'ordre p

Pour la loi de Student, on notera t_p le quantile d'ordre p

Pour la loi du Khi-deux, on notera z_p le quantile d'ordre p

Pour la loi de Fisher, on notera f_p le quantile d'ordre p

Propriétés :

Si X suit $N(\mu; \sigma^2)$ et a un réel $\longrightarrow X+a$ suit $N(\mu+a; \sigma^2)$

Si X suit $N(\mu; \sigma^2)$ et a un réel $\longrightarrow aX$ suit $N(a\mu; a^2\sigma^2)$

Si X suit $N(\mu_1; \sigma_1^2)$ et Y suit $N(\mu_2; \sigma_2^2)$ indépendantes $\longrightarrow X+Y$ suit $N(\mu_1+\mu_2; \sigma_1^2+\sigma_2^2)$
 $\longrightarrow X-Y$ suit $N(\mu_1-\mu_2; \sigma_1^2+\sigma_2^2)$

Si X_i suit $N(\mu; \sigma^2)$, $i=1, \dots, n$ indépendantes $\longrightarrow X_1 + \dots + X_n$ suit $N(n\mu; n\sigma^2)$
 $\longrightarrow \frac{X_1 + \dots + X_n}{n}$ suit $N(\mu; \sigma^2/n)$

Si X suit $N(\mu; \sigma^2)$ $\longrightarrow Y = (X - \mu)/\sigma$ suit $N(0; 1)$ [centrage-réduction]

Exemples :

Si X suit $N(3; 4)$ $\longrightarrow 2X-1$ suit $N(5; 16)$

Si X suit $N(3; 4)$ et Y suit $N(1; 9)$ indépendantes $\longrightarrow (2X-Y)$ suit $N(5; 25)$
 $\longrightarrow (2X-Y-5)/5$ suit $N(0; 1)$

Lecture de table de la loi Normale $N(0;1)$ - Exemples :

Si X suit la loi Normale $N(0;1)$ [loi tabulée] Lecture directe :

$$P(X < 0,51) = p \longrightarrow p = 0,695$$

$$P(X < u) = 0,95 \longrightarrow u = 1,6449$$

$$P(X > u) = 0,2 \text{ alors } P(X < u) = 0,8 \longrightarrow u = 0,8416$$

Lecture de table et centrage-réduction

Si X suit la loi $N(\mu; \sigma^2)$ alors $Y = (X - \mu)/\sigma$ suit la loi $N(0;1)$

$$\bullet \quad P(X < a) = p \Rightarrow P((X - \mu)/\sigma < (a - \mu)/\sigma) = P(Y < (a - \mu)/\sigma) = p$$

$$\longrightarrow \text{lecture de } u_p \text{ sur la table avec : } u_p = (a - \mu)/\sigma \Rightarrow a = \mu + \sigma u_p$$

• Si X suit la loi $N(3;4)$ alors $Y = (X - 3)/2$ suit la loi $N(0;1)$:

$$\star \text{ Si } P(X < 4) = p \Rightarrow P(Y < (4 - 3)/2) = p \Rightarrow P(Y < 1/2) = p \longrightarrow p = 0,6915$$

$$\star \text{ Si } P(X < a) = 0,9 \Rightarrow P(Y < (a - 3)/2) = 0,9 \Rightarrow P(Y < u) = 0,9$$

$$\longrightarrow \text{lecture de } u_{0,9} = 1,2816 = (a - 3)/2 \Rightarrow a = \mu + \sigma u = 3 + 2 \times 1,2816 = 5,5632$$

3. Théorème Central Limite : (Tous les théorèmes de convergence seront vus en L3)

Théorème Central Limite :

Soient X_1, \dots, X_n des variables aléatoires indépendantes de même loi, avec

$E(X_i) = \mu$ et $V(X_i) = \sigma^2$. Soit $Y = \sum X_i$ alors, si n est grand

$\frac{Y - n\mu}{\sigma\sqrt{n}}$ suit la loi $N(0; 1)$ ou Y suit la loi $N(n\mu; n\sigma^2)$

En pratique, on prendra : $n > 30$


Cas particulier :
Moivre-Laplace

Approximation d'une loi Binomiale par une loi Gaussienne

Soient X_i de loi $B(p)$ indépendantes, alors $\mu = p$ et $\sigma^2 = p(1-p)$

On sait que $Y = \sum_i X_i$ suit $B(n; p)$

Si n est grand, alors Y suit approx. $N(np; np(1-p))$



$$B(n; p) \approx N(np; np(1-p))$$

En pratique, on prendra : $n > 30$, $np > 5$, $n(1-p) > 5$

Approximation d'une loi de Poisson par une loi Gaussienne

Soit Y une v.a. de loi $P(\lambda)$. Si λ est grand, alors Y suit approx. $N(\lambda; \lambda)$



$$P(\lambda) \approx N(\lambda; \lambda)$$

En pratique, on prendra : $\lambda > 25$

Démo : Soit (X_i) un échantillon de taille n de loi $P(\lambda/n)$, alors $Y = \sum X_i$ suit une loi $P(\lambda)$
 – cf chapitre précédent -. De plus, $E(X_i) = V(X_i) = \lambda/n$. D'après le TCL, Y suit une loi $N(\lambda; \lambda)$

Exemple d'approximation :

Une certaine boîte mail affirme que la probabilité qu'un courriel soit classé en tant que 'spam' alors qu'il ne l'est pas réellement est $p=1\%$.

On prend un échantillon de 1000 mails. X suit la loi Binomiale (1000; 1%)

$$P(X \leq 15) = \binom{1000}{0} 0,01^0 (0,99)^{1000} + \dots + \binom{1000}{15} 0,01^{15} (0,99)^{985} = ???$$

Approximation : n grand $\longrightarrow n > 30 ; np=10 > 5 ; n(1-p)=990 > 5$

$$B(n; p) \approx N(np; np(1-p)) \quad \text{ici} \quad B(1000; 0,01) \approx N(10; 9,9)$$

$$P(X \leq 15) = P((X - 10)/\sqrt{9,9} \leq (15 - 10)/\sqrt{9,9}) = P(Y \leq 1,59) = 0,9441$$

\longrightarrow **Lecture $N(0;1)$**

4. Intervalle de fluctuation de la proportion :

Soit p la probabilité de succès d'un évènement A . Soit un n -échantillon indépendant.

X : “ *le nombre d'individus pour lequel l'évènement A a réussi* “, X suit la loi $B(n, p)$


La fréquence $F = X/n$ représente la proportion (dans l'échantillon) de réussites de A .

But : Trouver un intervalle $[a ; b]$ qui contient F avec une probabilité $1 - \alpha$:

$$P(a \leq F \leq b) = 1 - \alpha \quad \Rightarrow \quad \begin{array}{c} \text{F} \\ \text{---} [\text{---}] \text{---} \\ \text{a} \quad \quad \quad \text{b} \\ \quad \quad \quad 1-\alpha \end{array}$$

Si n est grand, alors F suit approximativement une loi $N(p, p(1-p)/n)$ – TCL (conditions).

$$P \left[\underbrace{(a - p) / \sqrt{p(1-p)/n}}_{-u_{1-\alpha/2}} \leq (F - p) / \sqrt{p(1-p)/n} \leq \underbrace{(b - p) / \sqrt{p(1-p)/n}}_{u_{1-\alpha/2}} \right] = 1 - \alpha$$



$$[a; b] = \left[p - u_{1-\alpha/2} \sqrt{p(1-p)/n} ; p + u_{1-\alpha/2} \sqrt{p(1-p)/n} \right]$$

Bon échantillonnage : si F est suffisamment proche de p
 si $F \in [a; b]$
 si $X \in [na; nb]$

Exemple :

Dans une boîte mail un courriel a une probabilité de 1% d'être classé comme un spam à tort. On prend un échantillon de taille 1000 mails. Soit X le nombre de mails classés „spam“ à tort. On repère 14 mails mal classés dans cet échantillon.

L'échantillon est-il ' bon', 'conforme' ? L'échantillon est-il “représentatif de la population totale“ ?

On cherche à savoir si le nombre de mails mal classés X est cohérent, donc si la fréquence F est bien dans l'intervalle de fluctuation à 95% :

$$I = [0,01 - 1,96 * 0,0031464; 0,01 + 1,96 * 0,0031464] = [0,00383; 0,01617]$$

Pour 14 mails mal classés dans l'échantillon, on a $F = 0,014$. On remarque que F est bien dans l'intervalle I . Ou bien : $14 \in [3,83; 16,17]$


L'échantillon est donc représentatif (ou conforme).

Intervalle de fluctuation de la moyenne :

Soit X une variable de loi $N(\mu; \sigma^2)$. Soit un n -échantillon indépendant.
La moyenne empirique \bar{X} suit la loi $N(\mu; \sigma^2/n)$. (μ et σ connus)


But : Trouver un intervalle $[a; b]$ qui contient \bar{X} avec une probabilité $1 - \alpha$:

$$P(a \leq \bar{X} \leq b) = 1 - \alpha$$



Raisonnement analogue à l'intervalle de fluctuation de la proportion : $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ suit une loi $N(0;1)$. Donc,

$$P \left[\underbrace{\frac{a - \mu}{\sigma/\sqrt{n}}}_{-u_{1-\alpha/2}} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq \underbrace{\frac{b - \mu}{\sigma/\sqrt{n}}}_{u_{1-\alpha/2}} \right] = 1 - \alpha$$



$$[a; b] = \left[\mu - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} ; \mu + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

Idem pour l'intervalle de fluctuation asymptotique - n grand - dans le cas où X ne serait pas Gaussienne (à faire en exo)

Exemple :

Le temps de compilation d'une page de codes avec la version 1 d'un logiciel était en moyenne de 0,2 seconde avec un écart type de 0,09 seconde. On suppose que ce temps suit une loi Normale. On s'intéresse à la version 2 du même logiciel. On prend un échantillon de 150 pages, la moyenne de compilation est de 0,18. Calculer l'intervalle de fluctuation de la moyenne à un niveau de confiance de 0,98, puis conclure si le temps de compilation moyen a varié entre les deux versions.

Dans la version 1, les paramètres sont connus. On cherche à savoir si cette nouvelle version est 'conforme' ou pas à l'ancienne.

Intervalle de fluctuation à 98% de la moyenne :

$$I = \left[0,2 - 2,3263 * 0,09 / \sqrt{(150)} ; 0,2 + 2,3263 * 0,09 / \sqrt{(150)} \right] = [0,183; 0,217]$$


On remarque que la moyenne $\bar{x} = 0,18$ n'est pas dans l'intervalle I, par valeur inférieure.

On conclut que le temps moyen de compilation a varié depuis l'ancienne version, il a diminué avec un niveau de confiance de 98%.

5. Quelques autres lois usuelles (liens avec la loi normale) :


- Soient X_1, \dots, X_n n variables indépendantes de loi $N(0; 1)$:

$$Z = \sum X_i^2 \text{ suit la loi du Khi - deux } \chi_n^2$$



- Soient X et Y deux variables indépendantes, avec X suit une loi $N(0; 1)$ et Y suit une loi χ_n^2 :

$$T = \frac{X}{\sqrt{Y/n}} \text{ suit la loi de Student } T_{(n)}$$



- Soient X et Y deux variables indépendantes de deux lois du Khi-deux à n et p degrés de liberté :

$$F = \frac{X/n}{Y/p} \text{ suit la loi de Fisher } F_{(n;p)}$$

