
STA401


Statistique et Calcul des Probabilités

Responsable : Carole Durand-Desprez

CHAPITRE 3: Estimation

1. Estimateurs – Maximum de vraisemblance :







Bonnes propriétés : qualités pour que les valeurs trouvées dans l'échantillon donnent une "bonne indication" sur le modèle de la population.

→ "bons" estimateurs

Estimateur :

Soit X une v.a. de loi de probabilité P, soit θ un paramètre de cette loi (ex : moyenne, variance ...). Soit (X_1, \ldots, X_n) un échantillon de taille n.

<u>Définition 1</u>: Un estimateur T_n de θ est une variable aléatoire fonction de l'échantillon.

$$\underline{Ex}$$
: $\bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i$ est un estimateur de l'espérance, mais ce n'est pas le seul !!

Qualités d'un estimateur

1) Convergent :
$$\lim_{n\to+\infty} P(|T_n-\theta|>\epsilon)=0 \quad \forall \epsilon>0$$

2) Sans biais :
$$E(T_n - \theta) = 0$$
 ou $E(T_n) = \theta$

3) Efficace: $V(T_n)$ est la plus petite possible: $V(T_n) \le V(T)$ ∀T estimateur

Exemple : Qualités de la moyenne empirique X :

– C' est un estimateur de E(X) ou μ . Voir chapitre précédent : $E(\bar{X}) = \mu$ et $V(\bar{X}) = \sigma^2/n$

- Sans biais :
$$E(\bar{X} - \mu) = \frac{1}{n} \sum E(X_i) - E(\mu) = \mu - \mu = 0$$

- Sans biais :
$$E(\bar{X} - \mu) = \frac{1}{n} \sum E(X_i) - E(\mu) = \mu - \mu = 0$$

- Convergent : Bienaymé Tchebychev $\rightarrow P(|\bar{X} - \mu| > \epsilon) \le \frac{V(\bar{X})}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2} \rightarrow 0$

– Variance asymptotiquement nulle : $V(\bar{X}) = \sigma^2/n \rightarrow 0$

Maximum de vraisemblance :



Soit X une v.a. de loi de densité f; soit θ un paramètre de cette loi (ex : moyenne, variance ...); soit (x_1, \ldots, x_n) un échantillon de taille n.


<u>Définition 2</u>: La vraisemblance de l'échantillon $(x_1, ..., x_n)$ pour θ est la fonction :

$$V(X,\theta) = f(x_{1,\dots},x_{n},\theta) = \prod_{i=1}^{n} f(x_{i},\theta)$$

<u>Définition 3</u>: L'estimateur du maximum de vraisemblance $\hat{\theta}$ est solution de :


$$Max_{\theta}\{V(X,\theta)\}$$
 ou bien $Max_{\theta}\{\ln(V(X,\theta))\}=Max_{\theta}\{\sum_{i=1}^{n}\ln(f(x_{1,\dots},x_{n},\theta))\}$

[La fonction In étant croissante, la transformation ne change pas le point réalisant le max]



$$\frac{\partial \ln(V(X,\theta))}{\partial \theta} = 0 \quad et \quad \frac{\partial^2 \ln(V(X,\theta))}{\partial \theta^2} \le 0$$


On cherche la valeur de θ qui rend l'échantillon $(x_1, ..., x_n)$ le plus probable.





Exemple: Estimateurs du maximum de vraisemblance de μ et σ^2 pour la loi $N(\mu;\sigma^2)$

$$\longrightarrow V(X,\mu) = \prod \left(\frac{1}{\sigma\sqrt{(2\pi)}} e^{\frac{-(x_i-\mu)^2}{2\sigma^2}} \right) = \left(\frac{1}{\sigma\sqrt{(2\pi)}} \right)^n e^{-\frac{1}{2\sigma^2}\sum (x_i-\mu)^2}$$



Estimateur du maximum de vraisemblance. Il est convergent, sans biais et asymptotiquement efficace.

Pour μ connue:

Estimateur du maximum de vraisemblance. Il est convergent, sans biais et asymptotiquement efficace.

POUR INFORMATION

Pour μ inconnue:

$$\frac{\partial \ln(V(X,\mu))}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i} (x_i - \mu)^2 = 0$$

$$\sum_{i} (x_i - \mu)^2 = \sum_{i} ((x_i - \bar{x}) + (\bar{x} - \mu))^2 = \sum_{i} (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2 + 2(\bar{x} - \mu) \sum_{i} (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2 + 2(\bar{x} - \mu)^2 + 2($$

$$S^2 = \frac{1}{n} \sum_{i} (X_i - \bar{X})^2$$

Estimateur du max. de vraisemblance de σ^2 . Il est convergent mais il a un biais.

$$E(S^{2}) = E\left(\frac{1}{n}\sum(X_{i})^{2} - \bar{X}^{2}\right) = \frac{1}{n}\sum E\left(X_{i}^{2}\right) - E(\bar{X}^{2}) = \frac{n}{n}(\sigma^{2} + \mu^{2}) - (\sigma^{2}/n + \mu^{2}) = \frac{n-1}{n}\sigma^{2}$$

$$\text{donc} \qquad E\left(\frac{n}{n-1}S^{2}\right) = \sigma^{2}$$

$$\longrightarrow S'^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$$

Estimateur convergent et sans biais de σ^2

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum X_i$$

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum X_i$$

$$\hat{\sigma}^2 = S'^2 = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$$

$$\hat{p} = F = \frac{K}{n}$$

$$\hat{p} = F = \frac{K}{n}$$

Les estimateurs

$\frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$ suit N(0; 1)

$$\frac{\bar{X} - \mu}{S'/\sqrt{n}} = \frac{\bar{X} - \mu}{S/\sqrt{n-1}} \quad suit \quad T_{n-1}$$

$$\frac{nS^2}{\sigma^2} = \frac{(n-1)S'^2}{\sigma^2} \quad suit \quad \aleph_{n-1}^2$$

$$\frac{F-p}{\sqrt{\frac{p(1-p)}{n}}} \quad suit \quad N(0;1)$$

Lois des estimateurs

$$\forall i, X_i \quad suit \quad N(\mu; \sigma^2) \quad alors$$
 $\bar{X} \quad suit \quad N\left(\mu; \frac{\sigma^2}{n}\right)$

$$\rightarrow$$
 T.C.L.

2. Intervalle de confiance

a/ Le principe

Trouver un intervalle [a;b] qui contient le paramètre θ avec une probabilité 1 - α :


$$P(a \le \theta \le b) = 1 - \alpha$$



 $P(a \le \theta \le b) = 1 - \alpha$ $\theta \in [a; b]$ avec un niveau de confiance de $1 - \alpha$



- Estimer le paramètre
- Loi de l'estimateur
- Lecture de table
- Calcul des bornes a et b



 α risque que θ ne soit pas dans l'intervalle $\langle --- \rangle$ 1- α confiance que θ y soit

Si α augmente alors l'intervalle diminue

Si α diminue alors l'intervalle augmente (L'intervalle de risque α = 0 est : \mathbb{R})

Amplitude de l'intervalle (ou longueur) : b-a

b/ Intervalle de confiance de μ avec σ^2 connue :

Trouver un intervalle [a;b] contenant μ avec une probabilité 1 - α : P(a < μ < b) = 1 - α

- $\hat{\mu} = \bar{X}$ et $\frac{X \mu}{\sigma / \sqrt{n}}$ suit N(0; 1) [σ^2 supposée connue]
- Construction:

$$1 - \alpha = P(a \le \mu \le b) = P\left(\underbrace{\frac{\bar{X} - b}{\sigma/\sqrt{n}}} \le \underbrace{\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}} \le \underbrace{\frac{\bar{X} - a}{\sigma/\sqrt{n}}}\right)$$

$$N(0; 1)$$


$$\Leftrightarrow 1 - \alpha = P(-u \le Y \le u)$$
$$1 - \frac{\alpha}{2} = P(Y \le u)$$

- Lire le quantile $u_{1-\alpha/2}$ sur la table N(0; 1)
- Calcul de a et b :

$$u_{1-\alpha/2} = \frac{\bar{X} - a}{\sigma/\sqrt{n}} \quad donc \qquad a = \bar{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$
$$-u_{1-\alpha/2} = \frac{\bar{X} - b}{\sigma/\sqrt{n}} \quad donc \qquad b = \bar{X} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

$$a = \bar{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

$$b = \bar{X} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$



$$I(\mu; \alpha) = [a; b]$$

c/ <u>Exemple</u>: X suit $N(\mu; \sigma^2)$ avec σ^2 connue, $\sigma^2=4$. Echantillon n=9, $\Sigma x_i = 900$.

- Moyenne empirique : $\bar{x} = 900/9 = 100$
- Moyenne estimée : $\hat{\mu} = \bar{x} = 100$
- <u>Variance connue</u> (pas empirique s², ni estimée s'²) : $\sigma^2 = 4$
- Intervalle de confiance de μ de niveau 95% :

$$\alpha = 5\%$$
, σ^2 connue, donc $I(\mu; \alpha) = \left[\bar{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}; \bar{X} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$
 $u_{0,975} = 1,96$ donc $I(\mu; 0,05) = \left[100 \pm 1,96 \times \frac{2}{\sqrt{9}} \right] = [100 \pm 1,33] = [98,67; 101,33]$

La moyenne de la population μ est comprise entre 98,67 et 101,33 avec 95% de confiance.

• La longueur de cet intervalle est : $\left| 2u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right| = 2 \times 1,33 = 2,66$

Remarques: Si α augmente alors $I(\mu)$ diminue. Si n augmente alors $I(\mu)$ diminue

- Pour une longueur L=2, trouver n ? (ou trouver α ?)
- a) $2u_{1-\alpha/2}\frac{\sigma}{\sqrt{n}} = L$ \Rightarrow $n = \left(2u_{1-\alpha/2}\frac{\sigma}{L}\right)^2$ Ici : n=16. [I diminue, n augmente.]
- b) $u_{1-\alpha/2} = \frac{L\sqrt{n}}{2\sigma}$ —> Lecture de table pour avoir p puis déduire α .

Ici, $u_{1-\alpha/2} = 1.5$; lecture de N(0;1), p = 0.9332. Or, $p=1-\alpha/2 \Rightarrow \alpha = 2(1-p)$. Donc: $\alpha = 13.36\%$ [I diminue, α augmente.]

d/ Construction de l'intervalle de la variance :

Trouver un intervalle [a;b] contenant σ^2 avec une probabilité 1 - α : P(a < σ^2 < b) = 1 - α


•
$$\widehat{\sigma^2} = S'^2$$
 et $\frac{nS^2}{\sigma^2} = \frac{(n-1)S'^2}{\sigma^2}$ suit \aleph_{n-1}^2

$$1 - \alpha = P(a \le \sigma^2 \le b) = P\left(\begin{array}{c} \frac{nS^2}{b} \le \frac{nS^2}{\sigma^2} \le \frac{nS^2}{a} \\ \hline z_1 & z_2 \end{array}\right)$$

$$1-\alpha=P(z_1\leq Y\leq z_2)\quad\Leftrightarrow\quad P(Y\leq z_1)=\alpha/2\quad et\quad P(Y\leq z_2)=1-\alpha/2$$

- Lire $\frac{Z_{\alpha/2}}{2}$ et $\frac{Z_{1-\alpha/2}}{2}$ sur la table \aleph_{n-1}^2
- $z_{\alpha/2}^{(n-1)} = \frac{nS^2}{b}$ et $z_{1-\alpha/2}^{(n-1)} = \frac{nS^2}{a}$ donc

$$I(\sigma^{2}; \alpha) = \left[\frac{nS^{2}}{z_{1-\alpha/2}^{(n-1)}} ; \frac{nS^{2}}{z_{\alpha/2}^{(n-1)}} \right]$$



Exemple: Pour un échantillon de taille n=10, on calcule s²=1,5. On prend α = 5%

$$z_{\alpha/2}^{(n-1)} = z_{0,025}^9 = 2,7 \quad et \quad z_{1-\alpha/2}^{(n-1)} = z_{0,975}^9 = 19,023$$

$$donc \quad I(\sigma^2; 0,05) = \left[\frac{15}{19,023}; \frac{15}{2,7}\right] = [0,7885; 5,555] \quad \text{La variance entre 0,78 et 5,55} \dots \text{ peu précis}$$

e/ Tous les intervalles de confiance (à savoir retrouver) :

Si σ^2 connue, $u_{1-\alpha/2}$ est le quantile d'ordre 1- $\alpha/2$ de la loi Normale N(0;1) :

$$I(\mu;\alpha) = \left[\overline{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} ; \overline{X} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right]$$

Si σ^2 inconnue, $t_{1-\alpha/2}^{n-1}$ est le quantile d'ordre 1- $\alpha/2$ de la loi Student T_{n-1} :

$$I(\mu;\alpha) = \left[\bar{X} - t_{1-\alpha/2}^{n-1} \, \frac{S'}{\sqrt{n}} \, ; \, \bar{X} + t_{1-\alpha/2}^{n-1} \, \frac{S'}{\sqrt{n}} \, \right]$$
 [moyenne]

Si grand échantillon $(n \ge 50)$:

$$I(\mu;\alpha) = \left[\bar{X} - u_{1-\alpha/2} \frac{S}{\sqrt{n}} ; \bar{X} + u_{1-\alpha/2} \frac{S}{\sqrt{n}} \right]$$

[moyenne]

$$I(p;\alpha) = \left[F - u_{1-\alpha/2} \sqrt{\frac{F(1-F)}{n}} ; F + u_{1-\alpha/2} \sqrt{\frac{F(1-F)}{n}} \right]$$

[probabilité]

Si $z_{\alpha/2}^{(n-1)}$ et $z_{1-\alpha/2}^{(n-1)}$ sont les quantiles d'ordre $\alpha/2$ et 1- $\alpha/2$ de la loi du Khi-deux \aleph_{n-1}^2

$$I(\sigma^{2}; \alpha) = \left[\frac{nS^{2}}{z_{1-\alpha/2}^{(n-1)}} ; \frac{nS^{2}}{z_{\alpha/2}^{(n-1)}} \right]$$

[variance]